ΠΑΝΕΠΙΣΤΗΜΙΟ ΑΙΓΑΙΟΥ

Τμήμα Μηχανικών Πληροφοριακών και Επικοινωνιακών Συστημάτων

ΘΕΩΡΗΤΙΚΗ ΕΡΓΑΣΙΑ

Μάθημα: Προηγμένα Θέματα Δικτύωσης · Καθηγητής: Σκιάνης Χαράλαμπος

Ακαδημαϊκό Έτος 2025–2026

Εφαρμογές Βαθιάς Μάθησης σε Συστήματα Ανίχνευσης Εισβολών Δικτύου:

Μια Κριτική Ανασκόπηση

Γρουζτίδης Σπυρίδων

Χριστάρας Ιωακείμ

Μάιος 2026

Λεξικό Όρων

AE (Autoencoder) — Νευρωνικό δίκτυο που συμπιέζει τα δεδομένα εισόδου σε χώρο χαμηλής διάστασης (encoder) και τα ανακατασκευάζει (decoder). Στο NIDS context, εκπαιδεύεται σε κανονική κυκλοφορία και ανιχνεύει ανωμαλίες μέσω υψηλού reconstruction error.

APT (Advanced Persistent Threat) — Εξελιγμένη, πολυβήματη επίθεση που εκτείνεται σε μεγάλο χρονικό διάστημα. Περιλαμβάνει φάσεις reconnaissance, initial access, lateral movement και data exfiltration, συνήθως εκτελούμενη από οργανωμένους αντιπάλους.

AUC (Area Under the ROC Curve) — Μετρική αξιολόγησης ταξινομητών που εκφράζει την ικανότητα διαχωρισμού κλάσεων ανεξάρτητα από threshold. Τιμή 1.0 = τέλεια διάκριση, 0.5 = τυχαία απόφαση.

CNN (Convolutional Neural Network) — Συνελικτικό νευρωνικό δίκτυο που ανιχνεύει τοπικά μοτίβα μέσω φίλτρων (kernels). Στο NIDS, επεξεργάζεται χαρακτηριστικά ροής είτε ως 1D ακολουθία είτε ως 2D εικόνα bytes, επιτυγχάνοντας υψηλή ταχύτητα και μικρό μέγεθος μοντέλου.

Concept Drift — Φαινόμενο όπου η στατιστική κατανομή των δεδομένων δικτύου αλλάζει με την πάροδο του χρόνου λόγω νέων εφαρμογών, πρωτοκόλλων ή τακτικών επιθέσεων, με αποτέλεσμα η απόδοση εκπαιδευμένων μοντέλων να υποβαθμίζεται.

DDoS (Distributed Denial of Service) — Κατανεμημένη επίθεση άρνησης υπηρεσίας. Πλήθος μολυσμένων συσκευών (botnet) στέλνουν ταυτόχρονα αιτήματα στον στόχο, καταρρέοντας τους διαθέσιμους πόρους. Μία από τις πιο διαδεδομένες κατηγορίες στα αξιολογούμενα datasets.

DL (Deep Learning / Βαθιά Μάθηση) — Υποπεδίο της μηχανικής μάθησης που χρησιμοποιεί νευρωνικά δίκτυα πολλαπλών στρωμάτων για αυτόματη εκμάθηση ιεραρχικών αναπαραστάσεων από δεδομένα, χωρίς χειροκίνητη μηχανική χαρακτηριστικών (feature engineering).

DNN (Deep Neural Network) — Πλήρως συνδεδεμένο βαθύ νευρωνικό δίκτυο (feed-forward) με πολλαπλά κρυφά στρώματα. Χρησιμοποιείται για supervised ταξινόμηση κυκλοφορίας σε κατηγορίες επίθεσης.

F1-Score — Αρμονικός μέσος Precision και Recall. Κατάλληλη μετρική για ανισόρροπα datasets όπου η ακρίβεια (accuracy) μπορεί να είναι παραπλανητική λόγω κυριαρχίας της πλειοψηφικής κλάσης.

False Positive Rate (FPR) — Ποσοστό καλοήθους κυκλοφορίας που ταξινομείται εσφαλμένα ως επίθεση. Κρίσιμος δείκτης για πρακτική χρηστικότητα: υψηλό FPR κατακλύζει τον SOC με ψευδείς συναγερμούς.

Federated Learning (FL) — Κατανεμημένο πρότυπο εκπαίδευσης μοντέλων όπου κάθε συμμετέχων κόμβος εκπαιδεύει τοπικά στα δικά του δεδομένα και κοινοποιεί μόνο τα gradients (ή βάρη) στον κεντρικό aggregator, μειώνοντας τη μεταφορά raw δεδομένων. Αυτό δεν αποτελεί από μόνο του εγγύηση ιδιωτικότητας ή κανονιστικής συμμόρφωσης: τα updates μπορεί να διαρρεύσουν πληροφορία και συνήθως απαιτούνται πρόσθετα μέτρα, όπως secure aggregation ή differential privacy.

Flow (Ροή δικτύου) — Σύνολο πακέτων που ανήκουν στην ίδια σύνδεση, ορισμένο από το 5-tuple: IP πηγής, IP προορισμού, θύρα πηγής, θύρα προορισμού, πρωτόκολλο. Αποτελεί τη βασική μονάδα ανάλυσης των περισσότερων NIDS.

GAN (Generative Adversarial Network) — Αρχιτεκτονική δύο ανταγωνιστικών δικτύων (generator και discriminator). Χρησιμοποιείται στο NIDS για augmentation συνθετικών δεδομένων επίθεσης και για adversarial testing ανιχνευτών.

IoT (Internet of Things) — Διαδίκτυο των Πραγμάτων: δίκτυο ετερογενών συσκευών (αισθητήρες, κάμερες, actuators) με περιορισμένους πόρους υπολογισμού. Το IoT αποτελεί ιδιαίτερα ευάλωτη επιφάνεια επίθεσης λόγω ασθενών μηχανισμών ασφαλείας.

Latency (Καθυστέρηση) — Ο χρόνος που απαιτείται για την κατάταξη μιας ροής δικτύου από το μοντέλο. Κρίσιμη παράμετρος για in-line IPS deployment όπου η ανίχνευση πρέπει να γίνεται σε πραγματικό χρόνο, με όριο που εξαρτάται από το traffic volume, το hardware και το σημείο επιβολής πολιτικής.

LSTM (Long Short-Term Memory) — Παραλλαγή RNN με gates που αντιμετωπίζουν το πρόβλημα του vanishing gradient, επιτρέποντας αποτύπωση μακροπρόθεσμων χρονικών εξαρτήσεων σε ακολουθίες πακέτων.

NIDS (Network Intrusion Detection System) — Σύστημα Ανίχνευσης Εισβολών Δικτύου: παρακολουθεί κυκλοφορία σε επίπεδο πακέτου ή ροής για εντοπισμό κακόβουλης δραστηριότητας. Χωρίζεται σε signature-based (βάσει γνωστών υπογραφών) και anomaly-based (βάσει απόκλισης από κανονικότητα).

Reconstruction Error (Σφάλμα Ανακατασκευής) — Η απόκλιση μεταξύ εισόδου και εξόδου ενός autoencoder. Χρησιμεύει ως σκορ ανωμαλίας: υψηλό error υποδηλώνει κυκλοφορία άγνωστη στο μοντέλο, πιθανώς κακόβουλη.

Self-Attention — Μηχανισμός του Transformer που υπολογίζει βάρη σημαντικότητας μεταξύ όλων των στοιχείων μιας ακολουθίας ταυτόχρονα (παράλληλα), επιτρέποντας αποτύπωση εξαρτήσεων οποιασδήποτε απόστασης.

SHAP (SHapley Additive exPlanations) — Μέθοδος ερμηνευσιμότητας μοντέλων βασισμένη σε θεωρία παιγνίων (Shapley values). Αποδίδει σε κάθε χαρακτηριστικό ποσοτική συνεισφορά στην πρόβλεψη, χρήσιμη για explainability στο NIDS context.

SOC (Security Operations Center) — Κέντρο Επιχειρήσεων Ασφαλείας: ομάδα αναλυτών που παρακολουθούν, ανιχνεύουν και αντιμετωπίζουν κυβερνοαπειλές σε πραγματικό χρόνο. Τα NIDS τροφοδοτούν το SOC με συναγερμούς για αξιολόγηση.

Transformer — Αρχιτεκτονική νευρωνικού δικτύου βασισμένη αποκλειστικά σε self-attention (Vaswani et al., 2017). Επεξεργάζεται ακολουθίες παράλληλα, αντιμετωπίζοντας το vanishing gradient των RNN, με πολυπλοκότητα $O(n^2)$ ως προς το μήκος ακολουθίας.

TLS 1.3 (Transport Layer Security) — Πρωτόκολλο κρυπτογράφησης επιπέδου μεταφοράς. Η υιοθέτησή του καθιστά αδύνατη την επιθεώρηση payload χωρίς man-in-the-middle υποδομή, αναγκάζοντας τα NIDS να βασίζονται σε metadata και side-channel χαρακτηριστικά.

VAE (Variational Autoencoder) — Πιθανοτική εκδοχή του autoencoder που μαθαίνει κατανομή πιθανότητας στον latent space, επιτρέποντας γεννητική χρήση (sampling νέων δειγμάτων) και πιο ρωμαλέα ανίχνευση ανωμαλιών.

Zero-Day — Άγνωστη ευπάθεια ή επίθεση για την οποία δεν υπάρχει ακόμα γνωστή υπογραφή ή διαθέσιμο patch. Τα anomaly-based NIDS, και ειδικά τα αυτοεπιβλεπόμενα (AE, VAE), είναι θεωρητικά ικανά να τα ανιχνεύσουν.

1. Περίληψη

Η παρούσα εργασία αποτελεί κριτική ανασκόπηση του άρθρου «A Survey on the Applications of Deep Learning in Network Intrusion Detection Systems to Enhance Network Security» των Fatima M. Anis, Maryam Alabdullatif, Sarah Aljbli και Mohammad Hammoudeh, δημοσιευμένου στο IEEE Access το 2025 (DOI: 10.1109/ACCESS.2025.3624952). Πρόκειται για survey άρθρο που ανασκοπεί 31 ερευνητικές μελέτες της περιόδου 2020–2025, οργανωμένες σε πρωτότυπη ταξινομία τεσσάρων κατηγοριών: (1) ανακατασκευαστικά και γεννητικά μοντέλα (Autoencoders, VAE, GAN), (2) μοντέλα βάσει Transformer, (3) συνελικτικά και feed-forward δίκτυα (CNN, DNN), και (4) υβριδικές και federated learning προσεγγίσεις.

Σκοπός δεν είναι η απλή περίληψη ευρημάτων, αλλά η κριτική αξιολόγηση της μεθοδολογικής αρτιότητας, η εξέταση αξιοπιστίας των αναφερόμενων benchmark αποτελεσμάτων και η ανάλυση πληρότητας των προτεινόμενων ερευνητικών κατευθύνσεων.

Η κριτική ανασκόπηση οργανώνεται σε τρία μέρη. Αρχικά παρουσιάζεται το ερευνητικό πλαίσιο: γιατί η βαθιά μάθηση αναδεικνύεται ως κεντρική προσέγγιση στα σύγχρονα NIDS και ποιες θεμελιώδεις αδυναμίες των παραδοσιακών συστημάτων καλείται να υπερκεράσει. Στη συνέχεια αναλύεται η ταξινομία και τα ευρήματα του άρθρου, με ιδιαίτερη έμφαση στα αποτελέσματα cross-dataset αξιολόγησης και στις πρακτικές συνέπειες deployment. Τέλος, αξιολογούνται κριτικά τόσο η μεθοδολογία όσο και οι προτεινόμενες ερευνητικές κατευθύνσεις, εντοπίζοντας ευρύτερες τάσεις και παραλείψεις του κλάδου.

1.1 Στοιχεία συγγραφέων και εξειδίκευση σε δίκτυα

Ο Mohammad Hammoudeh κατέχει την έδρα Saudi Aramco Chair Professor of Cybersecurity στο King Fahd University of Petroleum and Minerals (KFUPM). Είναι Senior Member του IEEE και Co-Editor-in-Chief του ACM Journal of Distributed Ledger Technology, με ερευνητικό έργο που εστιάζει σε zero-trust security, IoT, blockchain και κατανεμημένα συστήματα.

Η Maryam Alabdullatif είναι υποψήφια διδάκτορας στο KFUPM με μεταπτυχιακό στην Κυβερνοασφάλεια και Τεχνητή Νοημοσύνη από το Πανεπιστήμιο του Sheffield, ερευνώντας deep reinforcement learning για αντι-jamming στρατηγικές σε ασύρματα δίκτυα. Η Fatima M. Anis ολοκλήρωσε μεταπτυχιακό στο KFUPM (2025) με εξειδίκευση σε machine learning, ανίχνευση εισβολών και game-theoretic μοντέλα για APT. Η Sarah Aljbli είναι υποψήφια διδάκτορας με αντικείμενο ασφάλεια δικτύων, cloud security και IoT. Ως νέο δημοσίευμα (2025), ο αριθμός αναφορών αναμένεται να αυξηθεί σημαντικά τους επόμενους μήνες.

2. Εισαγωγή

2.1 Ερευνητικό πρόβλημα — γιατί DL για NIDS;

Το τοπίο των κυβερνοαπειλών έχει αλλάξει ριζικά τα τελευταία χρόνια. Επιθέσεις που παλαιότερα απαιτούσαν εξειδικευμένες γνώσεις εκτελούνται σήμερα μέσω as-a-service πλατφορμών, ενώ η επιφάνεια επίθεσης διευρύνεται συνεχώς — εκτιμάται ότι ο αριθμός συνδεδεμένων IoT συσκευών θα υπερβεί τα 30 δισεκατομμύρια παγκοσμίως μέχρι το 2030. Σύμφωνα με την IBM (2024), το μέσο κόστος παραβίασης δεδομένων έφτασε τα 4,88 εκατ. δολάρια, αύξηση ~10% έναντι του 2023 [9]. Ο μέσος χρόνος ανίχνευσης παραβίασης στις 194 ημέρες αποκαλύπτει το βαθύτερο πρόβλημα: η ανίχνευση εισβολών δεν χρειάζεται μόνο να είναι ακριβής, αλλά και έγκαιρη.

Τα Συστήματα Ανίχνευσης Εισβολών Δικτύου (NIDS) παρακολουθούν κυκλοφορία σε επίπεδο πακέτου ή ροής σε gateways και switches. Χωρίζονται παραδοσιακά σε δύο κατηγορίες. Τα signature-based συστήματα — Snort και Suricata είναι τα πιο γνωστά — αναγνωρίζουν γνωστές επιθέσεις μέσω αντιστοίχισης με προκαθορισμένα μοτίβα: αξιόπιστα για γνωστές απειλές, αλλά απολύτως τυφλά μπροστά σε νέες ή παραλλαγμένες. Τα anomaly-based συστήματα μοντελοποιούν τη «φυσιολογική» συμπεριφορά δικτύου και ανιχνεύουν αποκλίσεις: μπορούν θεωρητικά να εντοπίσουν zero-day επιθέσεις, αλλά παράγουν συχνά υψηλό false positive rate που καταντάει να κατακλύζει τους αναλυτές ασφαλείας.

Η βαθιά μάθηση (Deep Learning, DL) αντιμετωπίζει αυτές τις προκλήσεις μαθαίνοντας αυτόματα ιεραρχικές αναπαραστάσεις από δεδομένα, χωρίς χειροκίνητη μηχανική χαρακτηριστικών. Στο NIDS context αυτό έχει συγκεκριμένη αξία: τα χαρακτηριστικά κυκλοφορίας που ξεχωρίζουν επιθέσεις από κανονική κυκλοφορία δεν είναι πάντα αυτονόητα, και αλλάζουν με κάθε νέα μέθοδο επίθεσης. Τα DL μοντέλα μπορούν επίσης να αποτυπώσουν μη γραμμικές, σύνθετες σχέσεις που οι κλασικές μέθοδοι ML (SVM, Random Forest) αδυνατούν.

Αυτό δεν σημαίνει ότι η εφαρμογή DL σε NIDS είναι χωρίς εμπόδια. Μία κεντρική πρόκληση είναι η κρυπτογράφηση: η υιοθέτηση TLS 1.3 καθιστά αδύνατη την επιθεώρηση payload χωρίς man-in-the-middle υποδομή, αναγκάζοντας τα NIDS να βασίζονται αποκλειστικά σε metadata και side-channel χαρακτηριστικά — μέγεθος πακέτων, inter-arrival times, burst patterns, χαρακτηριστικά TLS handshake. Σε σύγχρονα enterprise δίκτυα, πάνω από το 80% της κυκλοφορίας είναι κρυπτογραφημένη. Η σημασία payload-agnostic μεθόδων είναι ξεκάθαρη. Επιπλέον, τα DL μοντέλα απαιτούν σημαντικούς υπολογιστικούς πόρους, κάτι που περιορίζει την εφαρμογή τους σε resource-constrained περιβάλλοντα όπως IoT gateways.

Ένα ακόμη ζήτημα αφορά την πολυπλοκότητα σύγχρονων επιθέσεων. Οι Advanced Persistent Threats (APT) δεν εκδηλώνονται σε μία ροή: αξιοποιούν πολλαπλά βήματα — reconnaissance, initial access, lateral movement, data exfiltration — εκτεινόμενα σε ώρες ή εβδομάδες. Η ανίχνευσή τους απαιτεί συσχέτιση γεγονότων σε μεγάλα χρονικά παράθυρα. Τα Transformers, με τη δυνατότητα αποτύπωσης μακρών χρονικών

εξαρτήσεων, και τα graph-based μοντέλα που μοντελοποιούν σχέσεις μεταξύ κόμβων, αναδεικνύονται ως πιο κατάλληλα για αυτόν τον τύπο απειλής.

Συνολικά, το DL υπόσχεται μια θεμελιώδη αλλαγή στο NIDS παράδειγμα: από τη στατική αντιστοίχιση υπογραφών στη δυναμική μάθηση κατανομών. Ωστόσο, η μετάφραση αυτής της υπόσχεσης σε ανεπτυγμένα, αξιόπιστα συστήματα παραγωγής εξαρτάται από παράγοντες που υπερβαίνουν την αρχιτεκτονική επιλογή: ποιότητα και αντιπροσωπευτικότητα δεδομένων εκπαίδευσης, ανθεκτικότητα σε adversarial παρεμβολές, latency συμβατή με πρωτόκολλα δικτύου, και δυνατότητα ερμηνείας αποφάσεων από αναλυτές ασφαλείας. Ο πίνακας που ακολουθεί συνοψίζει συγκριτικά τις κύριες κατηγορίες NIDS.

Κατηγορία	Μέθοδος ανίχνευσης	Παραδείγματα	Πλεονεκτήματα	Μειονεκτήματα
Signature-based	Αντιστοίχιση μοτίβων σε γνωστές επιθέσεις	Snort, Suricata	Χαμηλά false positives, γρήγορη εκτέλεση, αξιόπιστο	Τυφλό σε zero-day, συνεχής ενημέρωση signatures
Anomaly-based ML	Απόκλιση από statistical baseline	IsolationForest, kNN-IDS	Ανίχνευση άγνωστων επιθέσεων, μεγάλη κάλυψη	Υψηλά false positives, ευαίσθητο σε concept drift
DL-based NIDS	Αυτόματη εκμάθηση χαρακτηριστικών	CNN-IDS, FlowTransformer	Υψηλή ακρίβεια, ανίχνευση complex patterns	Υπολογιστικό κόστος, μειωμένη explainability
Hybrid NIDS	Συνδυασμός τεχνικών	CNN+RF, AE+DNN	Ισορροπία precision/recall, ευελιξία	Αυξημένη πολυπλοκότητα και δυσκολία deployment
Federated NIDS	Κατανεμημένη εκπαίδευση χωρίς κεντρικά δεδομένα	ResNet+FL, FedGAT	Privacy-preserving, IoT scalability	Επικοινωνιακό κόστος, client heterogeneity

Πίνακας 1: Κατηγορίες NIDS — μέθοδοι, παραδείγματα, πλεονεκτήματα και μειονεκτήματα

2.2 Μέθοδος ανασκόπησης βιβλιογραφίας και ερευνητικές ερωτήσεις

Η μεθοδολογία των Anis et al. (2025) εστιάζεται αποκλειστικά σε DL-based NIDS δημοσιευμένα μεταξύ 2020 και 2025. Τα κριτήρια ένταξης περιλαμβάνουν: (α) επαρκή πειραματική λεπτομέρεια για αναπαραγωγή, (β) χρήση ρεαλιστικών συνόλων δεδομένων δικτύου ή IoT, και (γ) αξιολόγηση σε ρεαλιστικά σενάρια ανίχνευσης. Το τελικό corpus αποτελείται από 31 μελέτες, οργανωμένες στην τεσσάρων-κατηγοριών ταξινομία που αποτελεί την κεντρική συνεισφορά του άρθρου.

Αξίζει να επισημανθεί ότι το άρθρο δεν ακολουθεί επίσημη PRISMA methodology — δεν παρέχει λεπτομέρειες για τις βάσεις δεδομένων που αναζητήθηκαν (IEEE Xplore; Scopus; ACM DL; arXiv;), τις ακριβείς λέξεις-κλειδιά, ούτε πόσα άρθρα αξιολογήθηκαν πριν την τελική επιλογή. Αυτή η απουσία μεθοδολογικής διαφάνειας, αν και συνηθισμένη σε

surveys πληροφορικής, καθιστά αδύνατη την αναπαραγωγή της διαδικασίας και ανοίγει ερωτήματα για πιθανό selection bias.

Οι ερευνητικές ερωτήσεις που διαπνέουν το άρθρο — έστω και χωρίς να διατυπώνονται ρητά — είναι: (1) Ποιες κατηγορίες DL αρχιτεκτονικών χρησιμοποιούνται σήμερα για NIDS και ποιες θεμελιώδεις υποθέσεις κάνει κάθε μία; (2) Ποια datasets χρησιμοποιούνται και ποιες αδυναμίες εμφανίζουν; (3) Ποια μοντέλα ταιριάζουν σε ποιο deployment context (edge, server, federated); (4) Ποιες ανοιχτές ερευνητικές προκλήσεις παραμένουν;

Πριν προχωρήσουμε, αξίζει να αναφερθεί το ευρύτερο πλαίσιο: ο τομέας της ασφάλειας δικτύων αντιμετωπίζει θεμελιώδη ασυμμετρία — ο επιτιθέμενος χρειάζεται να βρει ένα αδύναμο σημείο, ενώ ο αμυνόμενος πρέπει να προστατεύει τα πάντα ταυτόχρονα. Η αυτοματοποιημένη ανίχνευση εισβολών δεν επιλύει αυτή την ασυμμετρία, αλλά μειώνει τον dwell time — τον χρόνο που ο επιτιθέμενος ενεργεί απαρατήρητος, σήμερα κατά μέσο όρο πάνω από 190 ημέρες. Τα DL-based NIDS στοχεύουν ακριβώς σε αυτή τη μείωση.

2.3 Συσχέτιση με θέματα δικτύωσης του μαθήματος

Το άρθρο συνδέεται με πολλαπλές έννοιες του μαθήματος Προηγμένα Θέματα Δικτύωσης. Σε επίπεδο εξαγωγής πληροφοριών κυκλοφορίας, τα NIDS αναλύουν ροές (flows) που ορίζονται από το 5-tuple: IP πηγής, IP προορισμού, θύρα πηγής, θύρα προορισμού, πρωτόκολλο. Πρότυπα εξαγωγής ροής όπως NetFlow v5/v9 και IPFIX (RFC 7011) παράγουν τα flow-level χαρακτηριστικά που χρησιμοποιεί η πλειοψηφία των μελετών — διάρκεια ροής, αριθμός πακέτων, συνολικά bytes, κατανομή flags, inter-arrival times. Εργαλεία όπως το CICFlowMeter αυτοματοποιούν αυτή την εξαγωγή.

Η υιοθέτηση TLS 1.3 αφαιρεί τη δυνατότητα payload ανάλυσης, αναγκάζοντας τα NIDS να βασίζονται σε metadata και side-channel χαρακτηριστικά. Κατηγορίες επιθέσεων που αποτελούν βασικό μέρος της ύλης — DoS, DDoS, port scanning, botnet propagation, ARP spoofing, DNS amplification, Man-in-the-Middle — είναι ο πρωταρχικός στόχος ανίχνευσης των 31 μελετών. Η σύνδεση με federated learning αντικατοπτρίζει θέματα κατανεμημένων συστημάτων: κάθε κόμβος εκπαιδεύει τοπικά και μοιράζεται μόνο model gradients με κεντρικό aggregator (FedAvg [16]). Η αρχιτεκτονική αυτή αντικατοπτρίζει τη φυσική ιεραρχία σύγχρονων δικτύων: edge device → gateway → cloud/datacenter.

3. Ανάλυση — Κύρια Συνεισφορά του Άρθρου

Πριν από την ανάλυση των επιμέρους κατηγοριών, χρειάζεται να γίνει κατανοητό γιατί η συγκεκριμένη ταξινομία αξίζει προσοχή. Τα προηγούμενα surveys ταξινομούσαν κυρίως βάσει αρχιτεκτονικού τύπου ή πεδίου εφαρμογής (enterprise vs IoT). Η ταξινομία των Anis et al. ταξινομεί βάσει θεμελιώδους υπόθεσης — δηλαδή τι υποθέτει κάθε κατηγορία μοντέλων για τη φύση της απειλής. Αυτό έχει πρακτική σημασία: αναδεικνύει ότι η επιλογή μοντέλου δεν είναι απλώς τεχνικό ζήτημα αλλά αντικατοπτρίζει το threat model — ποιες επιθέσεις αναμένονται, πώς εκδηλώνονται, και ποιο είναι το ανεκτό false positive rate.

3.1 Η ταξινομία τεσσάρων κατηγοριών

Η κεντρική συνεισφορά του άρθρου είναι η εισαγωγή ενοποιημένης ταξινομίας τεσσάρων κατηγοριών για τα DL-based NIDS. Κάθε κατηγορία αντιπροσωπεύει διαφορετική θεμελιώδη υπόθεση για τη φύση του προβλήματος ανίχνευσης: τα ανακατασκευαστικά μοντέλα υποθέτουν ότι κανονική κυκλοφορία έχει χαμηλό reconstruction error και επιθέσεις αποκλίνουν· τα Transformers υποθέτουν ότι εισβολές εκδηλώνονται ως ανωμαλίες σε χρονικές ακολουθίες· τα CNN/DNN υποθέτουν τοπικά ανιχνεύσιμα μοτίβα σε feature vectors· τα υβριδικά/federated υποθέτουν ότι καμία μεμονωμένη προσέγγιση δεν αρκεί και τα δεδομένα δεν μπορούν να συγκεντρωθούν.

Κατηγορία	Βασικά μοντέλα	Θεμελιώδης υπόθεση	Κύρια χρήση	Τυπική απόδοση
Ανακατασκευαστικά & Γεννητικά	AE, LSTM-AE, VAE+CBAM, GAN, ET-SSL	Κανονική κυκλοφορία = χαμηλό reconstruction error	Zero-day, anomaly detection, augmentation	AUC 0.92–0.95 F1 0.90–0.99
Transformer-based	FlowTransformer, NIDS-GPT, MDT, TransECA-Net	Εισβολές = ανωμαλίες σε χρον. ακολουθίες	Χρονικές εξαρτήσεις, few-shot learning	F1 0.95–0.99+ +20% cross-set AUC
CNN & Feed-Forward	ABCNN-IDS, SPIN-IDS, Spectrogram CNN, DNN	Τοπικά μοτίβα στα χαρακτηριστικά ροής	Supervised classification, edge deployment	Acc/F1 0.98–0.999 <2 ms/flow
Υβριδικά & Federated	CNN+RF, CNN+BiGRU, ResNet+FL, FedGAT	Καμία μεμονωμένη προσέγγιση δεν αρκεί	Privacy-preserving, IoT scalability	~94–99% vs ~99% centralized

Πίνακας 2: Ταξινομία DL-based NIDS — βασικές υποθέσεις, χρήση και απόδοση (Anis et al., 2025)

3.2 Ανακατασκευαστικά και γεννητικά μοντέλα

3.2.1 Autoencoder-based μοντέλα

Ένας autoencoder (AE) αποτελείται από encoder που συμπιέζει τα χαρακτηριστικά εισόδου σε latent space και decoder που προσπαθεί να ανακατασκευάσει την αρχική

είσοδο. Εκπαιδεύεται αποκλειστικά σε καλοήθη κυκλοφορία. Κατά την αξιολόγηση, το reconstruction error χρησιμοποιείται ως σκορ ανωμαλίας: υψηλό error υποδηλώνει κυκλοφορία που απέχει από ό,τι έχει δει το μοντέλο κατά την εκπαίδευση. Αυτή η προσέγγιση επιτρέπει ανίχνευση zero-day επιθέσεων, χωρίς labeled attack data.

Μια αντιπροσωπευτική μελέτη συγκρίνει πέντε παραλλαγές AE — standard, sparse, denoising, contractive, και convolutional — εκπαιδευμένες σε καλοήθεις ροές από NSL-KDD και UNSW-NB15. Το contractive AE επιτυγχάνει AUC 0.92–0.93 και F1 ~90%. Ο ορισμός του threshold ανωμαλίας παραμένει κρίσιμη παράμετρος: χαμηλό threshold αυξάνει ευαισθησία αλλά και false positives, υψηλό κάνει το αντίθετο. Στην πράξη η ρύθμιση αυτή εξαρτάται από το deployment environment και τις προτεραιότητες του οργανισμού.

Ένα LSTM-AE για Internet of Vehicles (IoV) μοντελοποιεί ακολουθίες CAN bus και network-flow ως χρονικά διατεταγμένα vectors, αναφέροντας ~99% ακρίβεια στο Car-Hacking dataset και ~98% στο UNSW-NB15 [13]. Η προσθήκη LSTM επιτρέπει αποτύπωση χρονικών εξαρτήσεων μεταξύ διαδοχικών πακέτων — χρήσιμο για multi-step επιθέσεις. Περιορισμοί: το binary anomaly label δεν επιτρέπει κατηγοριοποίηση τύπου επίθεσης, και η sequential LSTM επεξεργασία εισάγει latency. Μια τρίτη προσέγγιση αξιοποιεί convolutional VAE με CBAM (Convolutional Block Attention Module) στο CIC-IDS2017, αναφέροντας 99.52% ακρίβεια — η διπλή εκπαίδευση (VAE pretraining + CNN fine-tuning) αυξάνει πολυπλοκότητα αλλά βελτιώνει ουσιαστικά την ανίχνευση minority κλάσεων.

Από υλοποιητική άποψη, ένα σημαντικό πλεονέκτημα των AE είναι η δυνατότητα unsupervised εκπαίδευσης: δεν απαιτούν labeled δεδομένα επίθεσης, τα οποία είναι συχνά ελλιπή ή δύσκολο να αποκτηθούν σε πραγματικά δίκτυα. Ωστόσο, η απουσία επισήμανσης εισάγει αβεβαιότητα στη βαθμονόμηση του threshold: η επιλογή του ορίου πάνω από το οποίο ένα reconstruction error θεωρείται “ανώμαλο” είναι εν τέλει υποκειμενική και εξαρτάται από το risk appetite του οργανισμού. Σε συστήματα υψηλής διαθεσιμότητας (κρίσιμες υποδομές, νοσοκομεία), το κόστος ενός false negative είναι κατά κανόνα υψηλότερο από εκείνο ενός false positive, οδηγώντας σε χαμηλότερα thresholds και αυξημένο φόρτο για τους αναλυτές SOC.

3.2.2 Γεννητικά και self-supervised μοντέλα

Τα GAN αξιοποιούνται στο NIDS context με δύο τρόπους. Πρώτον, ως εργαλείο augmentation: το «SYN-GAN» εκπαιδεύει ξεχωριστό GAN ανά κλάση επίθεσης, δημιουργώντας συνθετικά δείγματα για βελτίωση της ισορροπίας training sets. Αξιολογείται στα UNSW-NB15, NSL-KDD και BoT-IoT επιτυγχάνοντας ακρίβειες ~90%, ~84% και 100% αντίστοιχα — ιδιαίτερα χρήσιμο για κατηγορίες επιθέσεων με ελάχιστα δείγματα, όπως το Infiltration (<0.1% ροών στο CIC-IDS2017).

Δεύτερον, ως εργαλείο adversarial testing: ένα self-attention GAN δημιουργεί κυκλοφορία που αναδεικνύει τυφλά σημεία black-box IDS. Αυτή η χρήση δεν κατασκευάζει ο ίδιος NIDS — βοηθά έμμεσα αποκαλύπτοντας αδυναμίες. Το σύστημα ET-SSL εφαρμόζει contrastive self-supervised learning σε metadata κρυπτογραφημένης κυκλοφορίας (CIC-

Darknet2020, ISCX VPN-nonVPN, UNSW-NB15), μαθαίνοντας payload-agnostic embeddings. Επιτυγχάνει detection rate >95% και zero-day true positive rate >92% με latency 15–25 ms ανά ροή — κατάλληλο για δίκτυα με κυρίαρχα TLS κρυπτογραφημένη κυκλοφορία.

Αξιολογώντας συνολικά την κατηγορία, τα AE-based μοντέλα τείνουν να χάνουν κατηγοριοποίηση: γνωρίζουν ότι κάτι είναι ανώμαλο αλλά όχι τι είδους επίθεση. Για SOC environments όπου απαιτείται ταξινόμηση για αντίδραση, η συνδυαστική χρήση AE (ανίχνευση ανωμαλίας) + DNN/CNN (ταξινόμηση) φαίνεται πλέον πρακτική προσέγγιση.

3.3 Μοντέλα βάσει Transformer

3.3.1 Βασικές αρχιτεκτονικές και αποτελέσματα

Τα Transformers [15] βασίζονται στον μηχανισμό self-attention που επιτρέπει παράλληλη αποτύπωση εξαρτήσεων μεταξύ οποιωνδήποτε θέσεων σε ακολουθία, ανεξαρτήτως απόστασης. Αυτό τα διαφοροποιεί από RNN/LSTM (sequential επεξεργασία, vanishing gradients) και CNN (σταθερό receptive field). Στο NIDS context, η δυνατότητα αυτή σημαίνει ότι μπορούν να ανιχνεύσουν επιθέσεις που εκδηλώνονται ως μακροχρόνιες, εξελισσόμενες ανωμαλίες σε ακολουθίες πακέτων.

Το FlowTransformer [8] παρέχει αρθρωτό framework με εναλλάξιμους κωδικοποιητές (GPT-2, BERT-style), αξιολογημένο σε KDD Cup'99, UNSW-NB15 και CIC-IDS2017. Με μόνο δύο Transformer layers επιτυγχάνει F1 >0.97, και τα ελαφρύτερα μοντέλα μειώνουν latency με ελάχιστη απώλεια ακρίβειας — αξιοσημείωτο εύρημα. Ένα Transformer εκπαιδευμένο στο CIC-IoT-2023 (46 εκατ. ροές, 33 τύποι επιθέσεων) επιτυγχάνει 99.40% within-dataset αλλά μόλις 88.25% στο ToN-IoT. Αυτό το cross-dataset generalization gap αφορά άμεσα την πραγματική χρηστικότητα.

Το Multi-Domain Transformer (MDT) αποτελεί ίσως το πιο ενδιαφέρον σύστημα από άποψη deployment: αναλύει time series επιπέδου πακέτου εμπλουτισμένα με Fourier χαρακτηριστικά και επιτυγχάνει F1 67.4% από τα πρώτα 0.1 δευτερόλεπτα μιας ροής, >94% έχοντας παρατηρήσει το 40% της ροής, και 98% F1 με το 23%. Για in-line IPS deployment αυτό σημαίνει ανίχνευση ενώ η επίθεση βρίσκεται ακόμα σε εξέλιξη.

Πρέπει να σημειωθεί ότι τα Transformers παρουσιάζουν συγκεκριμένα μειονεκτήματα στο NIDS context. Η πολυπλοκότητα του self-attention είναι $O(n^2)$ ως προς το μήκος ακολουθίας: μακρές ακολουθίες πακέτων αυξάνουν δραματικά τις απαιτήσεις μνήμης και χρόνου. Επίσης απαιτούν σημαντικά περισσότερα labeled examples για fine-tuning σε σχέση με CNN. Ένα λεπτό αλλά σημαντικό εύρημα του corpus: τα ελαφρύτερα Transformer μοντέλα (2 layers) αποδίδουν σχεδόν εξίσου με βαθύτερα, υποδηλώνοντας ότι η αυξημένη πολυπλοκότητα δεν δικαιολογείται πάντα.

3.3.2 Προχωρημένες Transformer προσεγγίσεις

Το NIDS-GPT αντιμετωπίζει πακέτα ως ακολουθίες bytes με field-aware markers (αρχή IP header, TCP header κλπ.) και αξιοποιεί GPT-2 αρχιτεκτονική. Η unsupervised προπαίδευση σε μη-επισημασμένα δεδομένα ακολουθείται από few-shot fine-tuning.

Ανιχνεύει minority class με αναλογία 1:1000 στο 100% και εμφανίζει ~95% transfer accuracy — αξιοσημείωτο για σενάρια με σπάνιες επιθέσεις, με κόστος την υψηλή υπολογιστική πολυπλοκότητα. Το TransECA-Net, σχεδιασμένο για κρυπτογραφημένη κυκλοφορία, συνδυάζει CNN, efficient channel attention (ECA) και Transformer encoder, επιτυγχάνοντας 98.25% σε 12 κλάσεις VPN traffic — 6.2–14.8% καλύτερα από CNN-LSTM baselines, με 40–49% ταχύτερη σύγκλιση.

3.4 Συνελικτικά και feed-forward δίκτυα

Τα CNN και DNN είναι η πιο διαδεδομένη κατηγορία, κυρίως λόγω υπολογιστικής αποδοτικότητας. Μικρά CNN εκτελούνται σε <2ms ανά ροή σε ARM-class CPU με <1MB μνήμη — χαρακτηριστικά που καθιστούν δυνατό το edge deployment σε IoT gateways. Το ABCNN-IDS (CNN με attention-based feature weighting και mutual information filtering) αναφέρει 99.81% μέση ακρίβεια σε τέσσερα IoT datasets, αλλά η απουσία αξιολόγησης σε resource-constrained hardware περιορίζει τη χρησιμότητα αυτού του αριθμού για πρακτικές αποφάσεις.

Το SPIN-IDS μετατρέπει σύντομες ακολουθίες πακέτων σε byte images κωδικοποιώντας επικεφαλίδες, περιεχόμενο και χρονική σειρά, επιτυγχάνοντας 97.7%–99% ακρίβεια και ~98% cross-dataset transferability. Είναι από τις ελάχιστες μελέτες που αξιολογούν ρητά ανθεκτικότητα σε adversarial διαταραχές. Ένα spectrogram-based CNN με Short-Time Fourier Transform (STFT) επιτυγχάνει ~99.5% σε DoS/DDoS ανίχνευση με γενίκευση μεταξύ CSE-CIC-IDS2018 και NSL-KDD. Ένα multi-task DNN που προβλέπει ταυτόχρονα δύο ετικέτες επιτυγχάνει ~87.5% έναντι ~81% single-task baselines, αναδεικνύοντας τη χρησιμότητα κοινής αναπαράστασης.

Μια σημαντική παρατήρηση για τα CNN: η απόδοσή τους εξαρτάται κρίσιμα από την αναπαράσταση εισόδου. Τα 1D CNN επεξεργάζονται χαρακτηριστικά ροής ως ακολουθία — κατάλληλο για χρονικές εξαρτήσεις εντός ροής. Τα 2D CNN αντιμετωπίζουν την κυκλοφορία ως εικόνα — κατάλληλο για χωρική δομή. Αυτή η επιλογή επηρεάζει τόσο τον τύπο επιθέσεων που ανιχνεύεται όσο και το preprocessing overhead. Η βελτιστοποίηση hyperparameters μέσω genetic algorithms αποδεικνύει την αξία automated search, αλλά το offline κόστος — ώρες σε GPU — περιορίζει τις συχνές επανεκπαιδεύσεις.

3.5 Υβριδικά μοντέλα και federated learning

Τα federated NIDS εξετάζουν πώς μπορεί να εκπαιδευτεί ένα μοντέλο ανίχνευσης χωρίς κεντρική συλλογή της ακατέργαστης κυκλοφορίας. Στο federated learning μοντέλο (βασισμένο στον FedAvg [16]), κάθε κόμβος εκπαιδεύει τοπικά και κοινοποιεί model updates σε έναν aggregation server. Η προσέγγιση περιορίζει τη μεταφορά raw δεδομένων, αλλά δεν εγγυάται GDPR/HIPAA compliance ή προστασία από gradient leakage χωρίς πρόσθετους τεχνικούς και οργανωτικούς ελέγχους.

Μια μεγάλης κλίμακας μελέτη σε Raspberry Pi (10–150 clients, CIC-IoT2023, 3.8 εκατ. ροές) συγκρίνει DNN, CNN και CNN+BiLSTM με FedAvg: το CNN επιτυγχάνει ~98% με 10 clients και ~94% με 150, ενώ το CNN+BiLSTM αποτυγχάνει σε IoT hardware λόγω memory constraints. Ένα federated Graph Attention Network (FedGAT, 23 layers)

επιτυγχάνει 95–97% με μερική explainability μέσω attention weights, αλλά το κόστος κατασκευής γράφου το αποκλείει από real-time χρήση. Μια τρίτη μελέτη συνδυάζει autoencoder (unsupervised) με DNN (supervised) υπό FL στο N-BaIoT: ο AE αποδεικνύεται πιο αξιόπιστος για anomaly detection υπό federation (F1 0.99), υποδηλώνοντας ότι unsupervised μοντέλα ανταποκρίνονται καλύτερα στη διαφορετικότητα κατανεμημένων clients.

Ένα ResNet με FL σε βιομηχανικό IoT (X-IIoTID, 10+ layers) επιτυγχάνει ~99.2–99.4%, αλλά το dataset δεν είναι δημοσίως διαθέσιμο — περιορισμός για reproducibility. Το gradient privacy risk παραμένει ανοιχτό: τα κοινόχρηστα gradients ενδέχεται να επιτρέπουν model inversion attacks. Η ενσωμάτωση differential privacy (προσθήκη noise στα gradients) μειώνει αυτόν τον κίνδυνο αλλά επηρεάζει την ακρίβεια του global μοντέλου. Αυτός ο θεμελιώδης συμβιβασμός privacy vs accuracy δεν αναλύεται επαρκώς στο corpus — κανένα paper δεν τον μελετά συστηματικά.

SOC

Deployment perspective — SOC: τα μεγάλα Transformer μοντέλα (FlowTransformer, NIDS-GPT) ταιριάζουν σε server-side SIEM ανάλυση (Splunk, Elastic SIEM) με batch inference. Τα CNN (<1MB, <2ms/flow) ταιριάζουν σε edge/gateway για πρωτοβάθμιο real-time φιλτράρισμα. Ένα υβριδικό δύο-επιπέδων σύστημα — edge CNN για fast first-pass + server Transformer για deep inspection — αντικατοπτρίζει ρεαλιστική enterprise αρχιτεκτονική που το άρθρο υπαινίσσεται χωρίς να αναπτύσσει ρητά.

3.6 Ανάλυση datasets — ταξινόμηση και κριτικά συμπεράσματα

Οι 31 μελέτες βασίζονται σε σχετικά μικρό αριθμό datasets: το CIC-IDS2017 κυριαρχεί (12/31), ακολουθούμενο από UNSW-NB15 (6/31) και NSL-KDD (5/31) [11, 12]. Η δημοτικότητά τους οφείλεται στη σαφή δομή, τα δημόσια pipelines εξαγωγής (CICFlowMeter) και στο ότι έχουν χρησιμοποιηθεί τόσο πολύ που η σύγκριση με προηγούμενα papers γίνεται εύκολη.

Dataset	Μελέτες	Ροές	Κατηγορίες	Έτος	Κύρια αδυναμία
CIC-IDS2017 [11]	12/31	~2.8 εκατ.	15 επιθέσεις	2017	Εργαστηριακό, ακραίο class imbalance
UNSW-NB15 [12]	6/31	~2.5 εκατ.	9 κατηγορίες	2015	Παλαιωμένα attack patterns
NSL-KDD	5/31	~125K	5 κατηγορίες	2009	Γνωστά artifacts, data leakage
CIC-IoT2023	4/31	~46 εκατ.	33 τύποι	2023	Εργαστηριακό, δεν αντικατοπτρίζει real IoT
BoT-IoT	3/31	~73 εκατ.	5 κατηγορίες	2018	Κυριαρχία botnet traffic (>98%)
ISCX VPN-nonVPN	2/31	—	VPN/non-VPN	2016	Παλαιωμένες εφαρμογές και πρωτόκολλα

Πίνακας 3: Datasets που χρησιμοποιούνται στις 31 μελέτες — συχνότητα, χαρακτηριστικά και αδυναμίες

Τα datasets αυτά παρουσιάζουν σοβαρές αδυναμίες. Το CIC-IDS2017 δημιουργήθηκε σε ελεγχόμενο εργαστηριακό περιβάλλον με τεχνητά σενάρια· η κατανομή κυκλοφορίας είναι ακραία ανισόρροπη (Infiltration: <0.1% ροών) και ορισμένες κατηγορίες έχουν τόσο χαρακτηριστικά feature signatures που η within-dataset ταξινόμηση γίνεται τεχνητά εύκολη, φουσκώνοντας τις αναφερόμενες ακρίβειες. Το NSL-KDD παρουσιάζει γνωστό data leakage μεταξύ training και test features. Σε cross-domain αξιολόγηση — εκπαίδευση σε CIC-IDS2017 και αξιολόγηση σε ToN-IoT — η απόδοση πέφτει κατά 10–30 ποσοστιαίες μονάδες. Αυτό υποδηλώνει ότι τα 99%+ αποτελέσματα αντικατοπτρίζουν dataset-specific patterns παρά γενικευσιμότητα.

Από το 2023 παρατηρείται στροφή προς IoT datasets (CIC-IoT2023, BoT-IoT, ToN-IoT, Edge-IIoTset). Ωστόσο, αυτά δημιουργήθηκαν επίσης σε ελεγχόμενες συνθήκες χωρίς να αποτυπώνουν αμφίδρομη αλληλεπίδραση ετερογενών IoT συσκευών, μεταβλητότητα traffic patterns ή legitimate anomalies από network churn — παράγοντες που σε παραγωγικά συστήματα αυξάνουν σημαντικά τα false positives.

3.7 Σύγκριση με προηγούμενα surveys

Το άρθρο συγκρίνεται με έξι προηγούμενα surveys. Lansky et al. (2021) [2] προσέφεραν πρώτη συστηματική ταξινόμηση ανά DL οικογένεια, αλλά δεν καλύπτουν Transformers, GAN ή federated learning. Li et al. (2024) [3] καλύπτουν Transformers αλλά παραμένουν περιγραφικοί χωρίς cross-dataset evaluation. Yang et al. (2024) [4] εστιάζουν αποκλειστικά σε Deep Reinforcement Learning — εκτός scope. Issa et al. (2024) [5]: ευρεία κάλυψη αλλά παρουσιάζουν κλασικές ML μεθόδους ισότιμα με DL. Chinnasamy et al. (2025) [6]: 87 μελέτες με PRISMA methodology, εντυπωσιακή κάλυψη, αλλά χωρίς Transformers, GNNs και federated learning. Zhang et al. (2025) [7]: εστίαση σε spatiotemporal features και class imbalance.

Το υπό ανασκόπηση άρθρο είναι το μοναδικό που καλύπτει ταυτόχρονα AE/GAN, Transformers, CNN/DNN και Federated/Hybrid NIDS. Αξίζει να σημειωθεί ότι 87 μελέτες έναντι 31 δεν σημαίνουν αναγκαστικά καλύτερο survey: η εστίαση του corpus επιτρέπει βαθύτερη ανάλυση κάθε εργασίας, κάτι που φαίνεται στην παρουσίαση deployment χαρακτηριστικών και cross-study συσχετίσεων. Η ισορροπία βάθους vs πλάτους είναι γνωστό δίλημμα στον σχεδιασμό surveys και το άρθρο δεν το αντιμετωπίζει ρητά.

3.8 Ανοιχτές ερευνητικές προκλήσεις

Το άρθρο εντοπίζει έξι ανοιχτές προκλήσεις: (1) Ποιότητα datasets/class imbalance: GAN/VAE augmentation σπάνιων κατηγοριών, domain adaptation, αυστηρότερα cross-dataset evaluation frameworks. (2) Real-time deployment: model compression μέσω pruning, quantization, knowledge distillation· hardware acceleration μέσω FPGA· υποχρεωτική αναφορά throughput/latency σε κοινό hardware. (3) Απόρρητο/Federated Learning: differential privacy, secure multi-party computation, split learning. (4) Adversarial robustness: adversarial training, feature hardening, GAN-based traffic

generation. (5) Ερμηνευσιμότητα: SHAP [17] και LIME για attribution, visualization attention weights σε Transformers. (6) Cross-domain γενίκευση: domain adaptation, continual learning για προσαρμογή σε νέα traffic baselines.

4. Κριτική και Συμπεράσματα

4.1 Πλεονεκτήματα και συνεισφορά

Η σημαντικότερη συνεισφορά είναι η ενοποιημένη ταξινομία τεσσάρων κατηγοριών — δεν εμφανίζεται σε κανένα από τα έξι συγκριτικά surveys και αντικατοπτρίζει θεμελιώδεις διαφορές στις υποθέσεις, στόχους και trade-offs κάθε οικογένειας. Η cross-study σύνθεση 31 μελετών παρέχει πλαίσιο σύγκρισης χρήσιμο τόσο για ερευνητές όσο και για μηχανικούς. Η κάλυψη federated learning ως deployment-grade επιλογής — με πειραματικά αποτελέσματα σε Raspberry Pi — καλύπτει κενό που αγνοούν όλα τα αντίστοιχα surveys.

Σε εγκαταστάσεις όπου η συγκέντρωση raw κυκλοφορίας περιορίζεται από πολιτικές, συμβάσεις ή κανονιστικές απαιτήσεις, το FL αποτελεί μία πιθανή αρχιτεκτονική επιλογή. Η καταλληλότητά του εξαρτάται από threat modeling, ασφαλή συνάθροιση, προστασία των model updates και λειτουργικούς περιορισμούς. Επιπλέον, οι πρακτικές οδηγίες deployment (CNN για edge, Transformer για server) είναι αξιόλογες. Το άρθρο είναι από τα λίγα surveys που συζητά ρητά trade-offs μεταξύ ακρίβειας και latency, και μεταξύ centralized vs federated deployment — διαστάσεις που σπάνια εμφανίζονται σε αντίστοιχα surveys.

4.2 Κριτική ως προς τη μέθοδο ανασκόπησης

Ελλιπής μεθοδολογική τεκμηρίωση. Σε αντίθεση με τους Chinnasamy et al. (2025) [6] που χρησιμοποιούν PRISMA-guided approach αξιολογώντας 87 μελέτες, το άρθρο δεν παρέχει λεπτομέρειες για τις βάσεις δεδομένων, τις λέξεις-κλειδιά, ούτε πόσα papers εξετάστηκαν πριν την τελική επιλογή των 31. Η αναπαραγωγή της μεθοδολογίας είναι αδύνατη — θεμελιώδης απαίτηση οποιουδήποτε survey. Αυτό δεν είναι τεχνική παράλειψη, αλλά ζήτημα επιστημονικής αξιοπιστίας.

Πιθανός selection bias. Η επιλογή 31 papers χωρίς τεκμηριωμένα κριτήρια ενδέχεται να εισάγει publication bias: μελέτες με χαμηλότερα αποτελέσματα ή αρνητικά ευρήματα μπορεί να έχουν αποκλειστεί. Αυτό είναι γνωστό πρόβλημα σε surveys χωρίς systematic search protocol.

Ανεπαρκής αξιολόγηση αξιοπιστίας αποτελεσμάτων. Το άρθρο παρουσιάζει και συγκρίνει αποτελέσματα χωρίς να αμφισβητεί την αξιοπιστία τους. Ακρίβειες 99%+ σε datasets με γνωστό data leakage (NSL-KDD) ή τεχνητά χαρακτηριστικά (CIC-IDS2017) χρήζουν κριτικής. Ένα ισχυρό survey θα διαχώριζε ρητά αποτελέσματα within-dataset από cross-dataset και cross-domain.

Αυτή η παράλειψη έχει άμεσες πρακτικές συνέπειες. Ένας μηχανικός που διαβάζει «CNN επιτυγχάνει 99.8% ακρίβεια» χωρίς να γνωρίζει τον context μπορεί να υιοθετήσει ακατάλληλη αρχιτεκτονική για παραγωγικό σύστημα. Αυτή η ευθύνη — ειδικά των survey

papers που χρησιμοποιούνται ως οδηγοί — αναδεικνύει τη σημασία της κριτικής ανάγνωσης που επιχειρεί η παρούσα εργασία.

4.3 Κριτική ως προς τις ερευνητικές ερωτήσεις

Οι ερευνητικές ερωτήσεις εστιάζουν στο «ποιες αρχιτεκτονικές υπάρχουν και πώς αποδίδουν» — ορθές, αλλά ατελείς. Απουσιάζουν: «πόσο αξιόπιστα είναι τα αναφερόμενα αποτελέσματα;», «ποια αρχιτεκτονική ταιριάζει σε ποιο deployment context;», «ποιο είναι το false positive rate σε κλίμακα παραγωγικού δικτύου;». Σε ένα enterprise δίκτυο με εκατομμύρια ροές ημερησίως, ακόμα και 0.1% FPR σημαίνει χιλιάδες ψευδείς συναγερμούς που κατακλύζουν τον SOC. Κανένα από τα 31 papers δεν αξιολογεί FPR σε παραγωγική κλίμακα.

Απουσιάζει επίσης ερώτηση για τον ρεαλιστικό threat model: ποιες επιθέσεις είναι πράγματι συνηθισμένες έναντι ποιες αποτελούν εξεζητημένα εργαστηριακά σενάρια. Το pattern που ακολουθεί το άρθρο — παρουσίαση, σύγκριση, κατηγοριοποίηση — είναι συνηθισμένο σε surveys πληροφορικής, αλλά παραλείπει το επόμενο βήμα: κριτική αξιολόγηση αξιοπιστίας. Δεν είναι μοναδική αδυναμία του συγκεκριμένου άρθρου — αντικατοπτρίζει ευρύτερη τάση όπου η μέτρηση «πόσο καλά αποδίδει ένα μοντέλο σε dataset» έχει αντικαταστήσει το «πόσο αξιόπιστα είναι αυτά στην πράξη».

4.4 Κριτική ως προς τις ερευνητικές κατευθύνσεις

Ψευδώς «ανοιχτές» κατευθύνσεις. Ορισμένες κατευθύνσεις έχουν ήδη αντιμετωπιστεί στη βιβλιογραφία εκτός corpus. Το concept drift και το continual learning για NIDS έχουν ερευνηθεί σε εργασίες 2023–2025. Η adversarial training παρουσιάζεται ως μελλοντική κατεύθυνση, ενώ αποτελεί ήδη αντικείμενο δημοσιευμένων εργασιών. Ένα σύγχρονο survey οφείλει να ξεκαθαρίζει τη διαφορά μεταξύ «ερευνητικά ανοιχτού» και «απλώς εκτός corpus».

Adversarial robustness — ανεπαρκής συγκριτική αξιολόγηση. Το corpus περιλαμβάνει μεμονωμένες adversarial αξιολογήσεις και παραγωγή επιθετικής κυκλοφορίας, αλλά δεν παρέχει κοινό robustness benchmark ούτε συστηματική σύγκριση αμυντικών τεχνικών [18]. Σε πρακτικό περιβάλλον, εξελιγμένοι αντίπαλοι (APT groups) προσαρμόζουν κυκλοφορία μόλις αντιληφθούν παρουσία NIDS. Η αποσπασματική adversarial evaluation παραμένει ουσιώδες κενό για την αξιόπιστη μετάβαση από εργαστηριακά benchmarks σε παραγωγικά NIDS.

Ερμηνευσιμότητα — υποεκτιμημένοι περιορισμοί. Το άρθρο αναφέρει SHAP [17] και LIME ως λύσεις χωρίς να συζητά τους περιορισμούς τους: η SHAP attribution σε υψηλής διαστατικότητας flow features μπορεί να είναι παραπλανητική, και η ερμηνεία attention weights δεν εγγυάται faithfulness. Ο security analyst χρειάζεται ερμηνεία σε ανθρώπινο επίπεδο — «γιατί αυτή η ροή θεωρείται ύποπτη» — όχι αφηρημένα feature attribution scores.

Κρυπτογραφημένη κυκλοφορία — σοβαρή αναντιστοιχία. Μόνο 2–3 από τις 31 μελέτες αξιολογούνται αποκλειστικά σε κρυπτογραφημένα δεδομένα, ενώ >80% της enterprise κυκλοφορίας είναι κρυπτογραφημένη. Η ανάπτυξη μεθόδων που λειτουργούν χωρίς

payload inspection — όπως το ET-SSL — αντικατοπτρίζει ακριβώς αυτό που απαιτείται, αλλά υπο-εκπροσωπείται σημαντικά στο corpus.

4.5 Κριτική αδυναμιών — συνοπτικός πίνακας

Αδυναμία	Σοβαρότητα	Επίπτωση	Προτεινόμενη αντιμετώπιση
Ελλιπής μεθοδολ. τεκμηρίωση	★★★ Υψηλή	Αδύνατη αναπαραγωγή μεθοδολογίας	PRISMA-compliant reporting
Χωρίς κριτική στα αποτελέσματα	★★★ Υψηλή	Φουσκωμένες ακρίβειες παραμένουν αόρατες	Διαχωρισμός within- vs cross-dataset
Ανεπαρκής adversarial αξιολόγηση	★★★ Υψηλή	Μη συγκρίσιμη real-world robustness	Adversarial evaluation framework
Ψευδώς «ανοιχτές» κατευθύνσεις	★★ Μέτρια	Παραπλανητική εικόνα state-of-the-art	Systematic literature watch
Χωρίς runtime benchmarks	★★ Μέτρια	Αδύνατη σύγκριση deployment κόστους	Unified hardware baseline
Λίγα papers για κρυπτογρ. κυκλοφ.	★★ Μέτρια	Δεν αντικατοπτρίζει πραγματικά δίκτυα	TLS-aware evaluation datasets
Πιθανός selection bias	★ Χαμηλή	Εκλεκτικά θετικά αποτελέσματα	Negative results reporting

Πίνακας 4: Αδυναμίες του reviewed άρθρου — σοβαρότητα, επίπτωση και αντιμετώπιση

Η κριτική αυτή δεν στοχεύει στην υποτίμηση της συνεισφοράς, αλλά στην ανάδειξη της απόστασης μεταξύ ακαδημαϊκής αναφοράς και πρακτικής εφαρμογής — απόσταση που αφορά ολόκληρο τον κλάδο. Η βιβλιογραφία DL για NIDS χαρακτηρίζεται από αυτό που ο Sommer και Paxson (2010) [14] ονόμασαν «closed world assumption»: εκπαίδευση και αξιολόγηση σε κλειστά, ελεγχόμενα datasets που χάνουν την πολυπλοκότητα του πραγματικού κόσμου. Η επίλυση απαιτεί καλύτερα datasets, αυστηρότερα evaluation frameworks και στενότερη συνεργασία ακαδημαϊκής κοινότητας με practitioner community.

4.6 Κατευθύνσεις που παρελήφθησαν

Πέρα από τις έξι κατευθύνσεις του άρθρου, εντοπίζουμε αρκετές παραλείψεις. Πρώτον, αξιολόγηση DL-NIDS σε zero-trust αρχιτεκτονικές: σε αυτές κάθε ροή θεωρείται ύποπτη by default και ο NIDS λειτουργεί ως continuous verifier — διαφορετικό operational model από το παραδοσιακό perimeter defense. Δεύτερον, ολοκλήρωση με threat intelligence feeds: ενσωμάτωση γνωστών κακόβουλων IPs, νέων CVEs και MITRE ATT&CK patterns δυναμικά χωρίς πλήρη επανεκπαίδευση. Τρίτον, multi-tenant cloud deployment χωρίς cross-tenant privacy violations. Τέταρτον, standardization και interoperability για διευκόλυνση σύγκρισης αποτελεσμάτων.

Ιδιαίτερα σημαντική είναι η παράλειψη του concept drift in deployment: τα traffic patterns αλλάζουν συνεχώς με νέες εφαρμογές, πρωτόκολλα και αλλαγές υποδομής. Μοντέλα

εκπαιδευμένα μία φορά υποβαθμίζονται σταδιακά (model staleness). Εργασίες continual learning για NIDS 2023–2025 αντιμετωπίζουν ήδη αυτό, αλλά το corpus τα παρουσιάζει ως «ανοιχτό ζήτημα» χωρίς να αναγνωρίζει ότι υπάρχουν ήδη ερευνητικές προσπάθειες. Επίσης, το άρθρο δεν αναφέρεται σε frameworks όπως CAIDA datasets, PCAP replay frameworks ή Kitsune, χάνοντας την ευκαιρία να αναδείξει πιο ρεαλιστικές εναλλακτικές αξιολόγησης.

4.7 Συνολικό συμπέρασμα

Διαβάζοντας το άρθρο συνολικά, γίνεται φανερό ότι ο τομέας DL για NIDS βρίσκεται σε ενδιαφέρον σημείο: τα benchmark αποτελέσματα είναι εντυπωσιακά, αλλά η μετάφρασή τους σε πραγματικά δίκτυα παραμένει ανοιχτό ζήτημα. Τα datasets είναι εργαστηριακά, η adversarial αξιολόγηση δεν είναι συστηματική ούτε συγκρίσιμη, οι ισχυρισμοί για real-time ανίχνευση δεν τεκμηριώνονται με κοινά hardware benchmarks, και η μεθοδολογική διαφάνεια υστερεί. Αυτό δεν αναιρεί τη συνεισφορά — η ταξινομία, η συστηματική σύγκριση και η κάλυψη federated learning είναι ουσιαστικές. Αλλά αναδεικνύει ότι ο κλάδος χρειάζεται περισσότερη εστίαση στο «deploy and defend» και λιγότερη στο «train and benchmark».

Η ερώτηση που παραμένει ανοιχτή δεν είναι αν το deep learning μπορεί να βελτιώσει την ανίχνευση εισβολών — μπορεί, και τα στοιχεία το επιβεβαιώνουν. Η ερώτηση είναι υπό ποιες συνθήκες, σε ποιο κόστος, με ποια αξιοπιστία, και αν μπορεί να εξηγήσει τις αποφάσεις του σε έναν security analyst. Ο δρόμος από ένα μοντέλο με 99% ακρίβεια σε εργαστηριακό dataset ως ένα σύστημα που προστατεύει αξιόπιστα ένα adversarial, ετερογενές, κρυπτογραφημένο δίκτυο παραμένει μεγάλος.

Προτείνουμε ότι η πρόοδος του κλάδου εξαρτάται από τρεις στρατηγικές προτεραιότητες. Πρώτον, την ανάπτυξη standardized evaluation frameworks που να απαιτούν υποχρεωτικά cross-dataset αξιολόγηση, αναφορά FPR σε παραγωγική κλίμακα και μετρήσεις latency σε κοινό hardware baseline. Δεύτερον, την εντατικοποίηση της έρευνας σε payload-agnostic μεθόδους — η επικράτηση TLS 1.3 καθιστά αυτή την κατεύθυνση αναπόφευκτη. Τρίτον, τη στενότερη σύνδεση ακαδημαϊκής έρευνας και πρακτικής εφαρμογής: οι πραγματικοί SOC analysts, οι υποδομές παραγωγής και οι αντίπαλοι που συνεχώς προσαρμόζονται αποτελούν τη μόνη αξιόπιστη δοκιμή για τα DL-based NIDS. Ο κλάδος έχει αποδείξει τεχνική ικανότητα· η επόμενη πρόκληση είναι η μετατροπή αυτής της ικανότητας σε πρακτική, ανθεκτική και ερμηνεύσιμη ασφάλεια.

Βιβλιογραφία

[1] F. M. Anis, M. Alabdullatif, S. Aljbli, and M. Hammoudeh, «A Survey on the Applications of Deep Learning in Network Intrusion Detection Systems to Enhance Network Security,» IEEE Access, 2025. DOI: 10.1109/ACCESS.2025.3624952

[2] J. Lansky et al., «Deep learning-based intrusion detection systems: A systematic review,» IEEE Access, vol. 9, pp. 101574–101599, 2021. DOI: 10.1109/ACCESS.2021.3097247

[3] Z. Li et al., «Toward deep learning based intrusion detection system: A survey,» in Proc. BDE '24, ACM, 2024, pp. 25–32. DOI: 10.1145/3688574.3688578

[4] W. Yang, A. Acuto, Y. Zhou, and D. Wojtczak, «A survey for deep reinforcement learning based network intrusion detection,» arXiv:2410.07612, 2024.

[5] M. M. Issa, M. Aljanabi, and H. M. Muhialdeen, «Systematic literature review on intrusion detection systems,» Journal of Intelligent Systems, vol. 33, no. 1, 2024. DOI: 10.1515/jisys-2023-0248

[6] R. Chinnasamy et al., «Deep learning-driven methods for network-based intrusion detection systems: A systematic review,» ICT Express, vol. 11, no. 1, pp. 181–215, 2025. DOI: 10.1016/j.icte.2025.01.005

[7] Y. Zhang, R. C. Muniyandi, and F. Qamar, «A review of deep learning applications in intrusion detection systems,» Applied Sciences, vol. 15, no. 3, p. 1552, 2025. DOI: 10.3390/app15031552

[8] L. D. Manocchio et al., «FlowTransformer: A transformer framework for flow-based network intrusion detection systems,» Expert Systems with Applications, vol. 241, p. 122564, 2024. DOI: 10.1016/j.eswa.2023.122564

[9] IBM Security, «Cost of a Data Breach Report 2024,» IBM Corp., 2024. Available: https://newsroom.ibm.com/

[10] P. Mell, «NIST SP 800-94: Guide to Intrusion Detection and Prevention Systems,» NIST, 2007. Available: https://csrc.nist.gov/pubs/sp/800/94/final

[11] I. Sharafaldin, A. H. Lashkari, and A. A. Ghorbani, «Toward generating a new intrusion detection dataset and intrusion traffic characterization,» in Proc. ICISSP, 2018, pp. 108–116.

[12] N. Moustafa and J. Slay, «UNSW-NB15: A comprehensive data set for network intrusion detection systems,» in Proc. MilCIS, 2015. DOI: 10.1109/MilCIS.2015.7348942

[13] J. Ashraf et al., «Novel deep learning-enabled LSTM autoencoder architecture for discovering anomalous events from intelligent transportation systems,» IEEE Trans. ITS, vol. 22, no. 7, pp. 4507–4518, 2020.

[14] R. Sommer and V. Paxson, «Outside the closed world: On using machine learning for network intrusion detection,» in Proc. IEEE S&P, 2010, pp. 305–316. DOI: 10.1109/SP.2010.25

[15] A. Vaswani et al., «Attention Is All You Need,» in Advances in NeurIPS, vol. 30, 2017. [arXiv:1706.03762]

[16] H. B. McMahan et al., «Communication-Efficient Learning of Deep Networks from Decentralized Data,» in Proc. AISTATS, 2017, pp. 1273–1282.

[17] S. M. Lundberg and S.-I. Lee, «A Unified Approach to Interpreting Model Predictions,» in Advances in NeurIPS, vol. 30, 2017.

[18] N. Papernot et al., «The Limitations of Deep Learning in Adversarial Settings,» in Proc. IEEE EuroS&P, 2016, pp. 372–387.