Εφαρμογές Βαθιάς Μάθησης σε

Συστήματα Ανίχνευσης Εισβολών Δικτύου (NIDS)

Μια Κριτική Ανασκόπηση

Ανασκόπηση του άρθρου: Anis, Alabdullatif, Aljbli & Hammoudeh – IEEE Access, 2025

Γρουζτίδης Σπυρίδων · Χριστάρας Ιωακείμ
Προηγμένα Θέματα Δικτύωσης | Τμήμα Μηχανικών ΠΕΣ, Πανεπιστήμιο Αιγαίου | Μάιος 2026

Ερευνητικό Πλαίσιο: Γιατί DL για NIDS;

4.88M

Μέσο κόστος παραβίασης (IBM, 2024, +10% YoY)

194

Μέσες ημέρες ανίχνευσης παραβίασης (dwell time)

>80%

Enterprise κυκλοφορία κρυπτογραφημένη (TLS 1.3)

Αδυναμίες παραδοσιακών NIDS

- Signature-based: τυφλό σε zero-day & νέες παραλλαγές
- Anomaly-based: υψηλό false positive rate
- Αδυναμία ανάλυσης payload υπό TLS 1.3
- APT: εκτείνονται σε εβδομάδες, δεν ανιχνεύονται flow-level

Πλεονεκτήματα Deep Learning

- Αυτόματη εκμάθηση χαρακτηριστικών (no feature engineering)
- Ανίχνευση μη γραμμικών, σύνθετων μοτίβων
- Δυνατότητα zero-day ανίχνευσης (AE/GAN)
- Αποτύπωση χρονικών εξαρτήσεων (Transformer, LSTM)

Το Άρθρο — Anis et al., IEEE Access 2025

Survey 31 μελετών (2020–2025) — IEEE Access open-access

Ανακατασκευαστικά & Γεννητικά

AE, LSTM-AE, VAE+CBAM, GAN, ET-SSL

1

Transformer -based

FlowTransformer, NIDS-GPT, MDT, TransECA-Net

2

CNN & Feed-Forward

ABCNN-IDS, SPIN-IDS, Spectrogram CNN, DNN

3

Υβριδικά & Federated

CNN+RF, ResNet+FL, FedGAT, CNN+BiGRU

4

Κεντρική συνεισφορά: ταξινομία βάσει θεμελιώδους υπόθεσης για τη φύση της απειλής — όχι απλώς βάσει αρχιτεκτονικού τύπου

Κατηγορία 1: Ανακατασκευαστικά & Γεννητικά Μοντέλα



→ Εκπαίδευση μόνο σε benign κυκλοφορία. Επιθέσεις = υψηλό error = ανωμαλία

Μοντέλο	Datasets	Απόδοση
Contractive AE	NSL-KDD, UNSW-NB15	AUC 0.92–0.93, F1 ~90%
LSTM-AE (IoV)	Car-Hacking, UNSW-NB15	Acc ~99% / ~98%
VAE + CBAM	CIC-IDS2017	Acc 99.52%
ET-SSL (TLS)	CIC-Darknet2020, ISCX	DR >95%, ZD-TPR >92%, 15–25ms
SYN-GAN (augment)	UNSW-NB15, NSL-KDD, BoT-IoT	~90% / ~84% / 100%

⚡ *Πλεονέκτημα: zero-day ανίχνευση χωρίς labeled attack data* | ⚠ *Αδυναμία: binary label, όχι κατηγοριοποίηση τύπου επίθεσης*

Κατηγορία 2: Transformer-based NIDS

Self-Attention: O(n²)

Αποτύπωση εξαρτήσεων μεταξύ οποιωνδήποτε θέσεων σε ακολουθία — ιδανικό για multi-step APT ανίχνευση

MDT — Έγκαιρη Ανίχνευση

F1 67.4% @ 0.1sec | F1 94% @ 40% ροής | F1 98% @ 23%

Μοντέλο	Datasets	Απόδοση	Σημείωση
FlowTransformer [8]	KDD'99, UNSW-NB15, CIC-IDS2017	F1 >0.97 (2 layers)	Εναλλάξιμοι κωδ., GPT-2/BERT
Transformer (IoT)	CIC-IoT-2023 → ToN-IoT	99.40% → 88.25%	Cross-dataset gap
NIDS-GPT	Packet bytes (few-shot)	100% minority @1:1000, 95% transfer	Υψηλό υπολογ. κόστος
TransECA-Net	12 κλάσεις VPN traffic	98.25% (+6 –14.8% vs CNN-LSTM)	40–49% ταχύτερη σύγκλιση

⚠ Ελαφρύτερα Transformer (2 layers) ≈ βαθύτερα στο NIDS context — η αυξημένη πολυπλοκότητα δεν δικαιολογείται πάντα

Κατηγορία 3: CNN & Feed-Forward Networks

Edge deployment: <2ms/flow σε ARM CPU, <1MB μνήμη — κατάλληλο για IoT gateways & embedded συσκευές

ABCNN-IDS

Attention + mutual info filtering
4 IoT datasets

99.81%

Χωρίς resource-constrained eval

SPIN-IDS

Byte images από πακέτα
Ανθεκτικό σε adversarial

97.7–99%
~98% cross-dataset

Μία από λίγες αντ/ικές μελέτες

Spectrogram CNN (STFT)

DoS/DDoS ανίχνευση
CSE-CIC-IDS2018, NSL-KDD

~99.5%

STFT overhead αμελητέο

Multi-task DNN

2 labels ταυτόχρονα
UNSW-NB15 + CIC-IDS2017

~87.5%
vs 81% single-task

Κοινή αναπαράσταση χαρακτ.

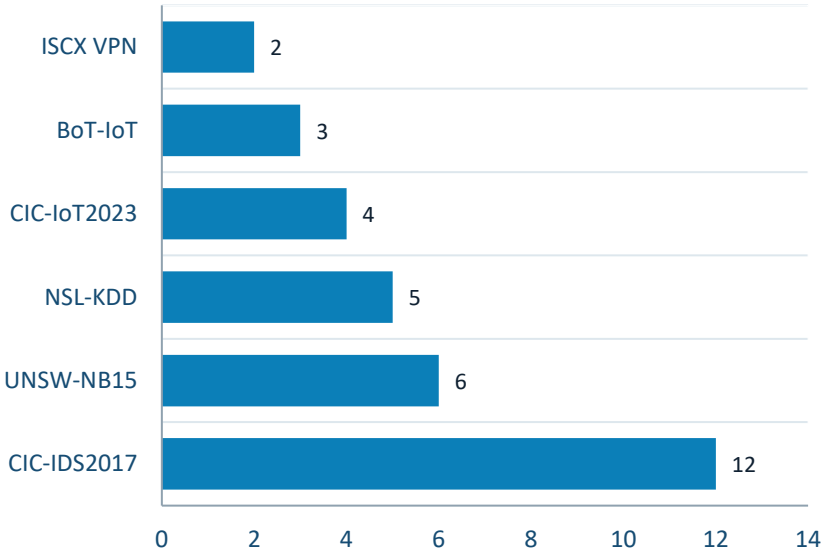
Κατηγορία 4: Υβριδικά Μοντέλα & Federated Learning

FedAvg [McMahan et al., 2017]: τοπική εκπαίδευση και κεντρική συνάθροιση updates. Περιορίζει τη μεταφορά raw traffic, αλλά δεν εγγυάται συμμόρφωση ή προστασία από gradient leakage.

Μοντέλο	Clients	Dataset	Απόδοση	Σημείωση
CNN (FedAvg)	10–150 (Raspi)	CIC-IoT2023	~98% @10 clients ~94% @150 clients	CNN+BiLSTM αποτυγχάνει IoT HW
FedGAT (23 layers)	Distributed	Graph-based	95–97%	Explainability (attention weights)
AE+DNN (FL)	Distributed	N-BaIoT	AE F1=0.99	Unsupervised ανθεκτικότερο σε FL
ResNet+FL	Industrial IoT	X-IIoTID	~99.2–99.4%	Dataset μη δημόσιο / reproducibility

⚠ *Gradient Privacy Risk: model inversion attacks — differential privacy αντισταθμίζει αλλά μειώνει ακρίβεια. Δεν αναλύεται συστηματικά στο corpus.*

Datasets — Συχνότητα Χρήσης & Κριτική Αξιολόγηση



Κύριες αδυναμίες datasets

- CIC-IDS2017: ακραίο class imbalance (Infiltration <0.1%), τεχνητά εργαστηριακά σενάρια
- NSL-KDD (2009): γνωστό data leakage μεταξύ train/test features
- Cross-domain: απόδοση πέφτει 10–30% (CIC-IDS2017 → ToN-IoT)
- IoT datasets: ελεγχόμενες συνθήκες, δεν αντικατοπτρίζουν real IoT
- >80% enterprise κυκλοφορίας κρυπτογραφημένη, ελάχιστα TLS datasets

Τα 99%+ αποτελέσματα αντικατοπτρίζουν dataset-specific patterns — όχι πραγματική γενικευσιμότητα («closed world assumption», Sommer & Paxson, 2010)

Deployment Context & SOC Architecture

EDGE / GATEWAY



CNN / DNN

- <2ms ανά ροή, <1MB RAM
- Πρωτοβάθμιο real-time φιλτράρισμα
- ARM-class CPU (Raspberry Pi)
- IoT gateways & switches



Suspicious flows

SERVER / SIEM



Transformer (FlowTransformer, NIDS-GPT)

- Batch inference, deep inspection
- Long-range temporal dependencies
- Splunk / Elastic SIEM integration
- APT & multi-session επιθέσεις

Το άρθρο υπαινίσσεται αυτή την αρχιτεκτονική χωρίς να την αναπτύσσει ρητά — πρακτική αξία για real enterprise deployment

Σύγκριση με 6 Προηγούμενα Surveys

Survey	AE/GAN	Transformer	Fed./Hybrid	Κάλυψη
Lansky et al. 2021 [2]	✓	✗	✗	9/31
Li et al. 2024 [3]	✗	✓	✗	~10/31
Yang et al. 2024 [4]	✗	✗	✗	DRL only
Issa et al. 2024 [5]	✓	✗	✗	ML+DL
Chinnasamy 2025 [6]	✓	✗	✗	87 papers
Zhang et al. 2025 [7]	✗	✗	✗	Spatiotempl.
Anis et al. 2025 ★	✓	✓	✓	31 papers

Μοναδικό survey που καλύπτει ταυτόχρονα AE/GAN + Transformers + Federated NIDS (2025)

Πλεονεκτήματα & Συνεισφορά

Πρωτότυπη Ταξινομία

Ταξινόμηση βάσει θεμελιώδους υπόθεσης (όχι απλώς αρχιτεκτονική) — αναδεικνύει ότι η επιλογή μοντέλου αντικατοπτρίζει το threat model

Cross-study Σύνθεση

Παράθεση datasets, αποτελεσμάτων και deployment cost για 31 μελέτες — χρήσιμο πλαίσιο τόσο για ερευνητές όσο και για μηχανικούς

Federated Learning Coverage

Πειραματικά αποτελέσματα σε Raspberry Pi. Το FL αποτελεί πιθανή επιλογή όταν δεν επιτρέπεται η συγκέντρωση raw traffic, αλλά απαιτεί επιπλέον privacy και security controls.

Πρακτικές Οδηγίες Deployment

Ρητή διάκριση: CNN για edge real-time (<2ms), Transformer για server deep inspection — σπάνιο σε αντίστοιχα surveys

Κριτική — Αδυναμίες του Άρθρου

★★★ Υψηλή

Ελλιπής μεθοδολογική τεκμηρίωση

Δεν ακολουθεί PRISMA. Απουσιάζουν: databases, keywords, πλήθος αξιολογηθέντων papers. Αδύνατη αναπαραγωγή.

★★★ Υψηλή

Χωρίς κριτική στα αποτελέσματα

Ακρίβειες 99%+ σε NSL-KDD (data leakage) ή CIC-IDS2017 (τεχνητά patterns) δεν αμφισβητούνται.

★★★ Υψηλή

Ελλιπής adversarial αξιολόγηση

Το corpus περιλαμβάνει adversarial attack generation, αλλά δεν προσφέρει ενιαίο robustness benchmark ούτε συστηματική σύγκριση defenses.

★★ Μέτρια

Ψευδώς «ανοιχτές» κατευθύνσεις

Continual learning, adversarial training ήδη ερευνώνται (2023–2025). Δεν γίνεται η διάκριση «ανοιχτό» vs «εκτός corpus».

★★ Μέτρια

Ελάχιστα TLS/κρυπτογρ. papers

Μόνο 2–3/31 αξιολογούνται αποκλειστικά σε κρυπτογραφημένα δεδομένα, ενώ >80% enterprise είναι TLS.

★ Χαμηλή

Πιθανός selection bias

31 papers χωρίς τεκμηριωμένα κριτήρια — ενδεχόμενη επιλογή papers με θετικά αποτελέσματα.

Ανοιχτές Ερευνητικές Κατευθύνσεις

1 Dataset Quality

GAN/VAE augmentation σπάνιων κλάσεων · Domain adaptation · Cross-dataset evaluation ως standard

2 Real-time Deployment

Model compression (pruning, quantization, distillation) · FPGA acceleration · Unified throughput/latency benchmarks

3 Adversarial Robustness ⚠

Adversarial training · Feature hardening · GAN-based traffic generation για exposure αδυναμιών

4 Federated Privacy

Differential privacy · Secure multi-party computation · Privacy vs accuracy trade-off (αδιερεύνητος)

5 Ερμηνευσιμότητα

SHAP/LIME με προσοχή στους περιορισμούς τους · Attention visualization ≠ faithfulness guarantee

6 Zero-Trust & Concept Drift

NIDS ως continuous verifier · Continual learning για model staleness (ήδη υπάρχουν εργασίες 2023–25)

Συμπέρασμα

«Ο δρόμος από ένα μοντέλο με 99% ακρίβεια σε dataset ως ένα σύστημα που προστατεύει αξιόπιστα ένα adversarial, κρυπτογραφημένο δίκτυο παραμένει μεγάλος.»

Αξία

Πρωτότυπη ταξινομία 4 κατηγοριών · FL coverage · Deployment-aware σύγκριση — χρήσιμο για ερευνητές & μηχανικούς

Αδυναμία

Απουσία PRISMA · Αδύνατη αναπαραγωγή · 99%+ ακρίβειες σε εργαστηριακά datasets δεν επαρκούν

Το Κρίσιμο Κενό

Adversarial robustness + TLS-aware evaluation + FPR σε παραγωγική κλίμακα = αδιερεύνητος τομέας

Βιβλιογραφία 1

[1] Anis, F. M. et al. A Survey on the Applications of Deep Learning in Network Intrusion Detection Systems to Enhance Network Security. IEEE Access, 2025. DOI: 10.1109/ACCESS.2025.3624952.

[2] Lansky, J. et al. Deep learning-based intrusion detection systems: A systematic review. IEEE Access 9, 2021. DOI: 10.1109/ACCESS.2021.3097247.

[3] Li, Z. et al. Toward deep learning based intrusion detection system: A survey. BDE 2024. DOI: 10.1145/3688574.3688578.

[4] Yang, W. et al. A survey for deep reinforcement learning based network intrusion detection. arXiv:2410.07612, 2024.

[5] Issa, M. M. et al. Systematic literature review on intrusion detection systems. Journal of Intelligent Systems 33(1), 2024. DOI: 10.1515/jisys-2023-0248.

[6] Chinnasamy, R. et al. Deep learning-driven methods for network-based intrusion detection systems: A systematic review. ICT Express 11(1), 2025. DOI: 10.1016/j.icte.2025.01.005.

[7] Zhang, Y. et al. A review of deep learning applications in intrusion detection systems. Applied Sciences 15(3), 2025. DOI: 10.3390/app15031552.

[8] Manocchio, L. D. et al. FlowTransformer: A transformer framework for flow-based NIDS. Expert Systems with Applications 241, 2024. DOI: 10.1016/j.eswa.2023.122564.

[9] IBM Security. Cost of a Data Breach Report 2024. IBM, 2024.

Βιβλιογραφία — συνέχεια

[10] Mell, P. Guide to Intrusion Detection and Prevention Systems. NIST SP 800-94, 2007.

[11] Sharafaldin, I. et al. Toward generating a new intrusion detection dataset and intrusion traffic characterization. ICISSP, 2018.

[12] Moustafa, N. and Slay, J. UNSW-NB15: A comprehensive data set for NIDS. MilCIS, 2015. DOI: 10.1109/MilCIS.2015.7348942.

[13] Ashraf, J. et al. LSTM autoencoder architecture for anomalous events in intelligent transportation systems. IEEE Transactions on ITS 22(7), 2020.

[14] Sommer, R. and Paxson, V. Outside the closed world: On using machine learning for network intrusion detection. IEEE S&P, 2010. DOI: 10.1109/SP.2010.25.

[15] Vaswani, A. et al. Attention Is All You Need. NeurIPS 30, 2017. arXiv:1706.03762.

[16] McMahan, H. B. et al. Communication-Efficient Learning of Deep Networks from Decentralized Data. AISTATS, 2017.

[17] Lundberg, S. M. and Lee, S.-I. A Unified Approach to Interpreting Model Predictions. NeurIPS 30, 2017.

[18] Papernot, N. et al. The Limitations of Deep Learning in Adversarial Settings. IEEE EuroS&P, 2016.